

Сходимость поверхности функции потерь как признак достаточного размера выборки

Отчет о научно-исследовательской работе

Киселев Никита Сергеевич

Научный руководитель: к.ф.-м.н. А. В. Грабовой

Московский физико-технический институт
(национальный исследовательский университет)
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Изменение поверхности функции потерь и достаточный размер выборки

Проблема

Исследуется ландшафт функции потерь в нейронных сетях. Рассматриваемая поверхность нетривиально зависит от выбранной архитектуры, функции потерь и обучающей выборки.

Цель

Оценить изменение поверхности функции потерь при добавлении обучающих данных. Связать это изменение с качеством модели на отложенной выборке.

Предлагается

1. Рассмотреть изменение функции потерь **в окрестности локального минимума**, используя аппроксимацию второго порядка;
2. Проанализировать связь качества модели на отложенной выборке с изменением поверхности функции ошибки на обучающем наборе данных.

Обзор полученных результатов




Рис. 1: Обзор результатов исследования. Часть (а) показывает ландшафт функции потерь, который является поверхностью в пространстве параметров. Часть (б) показывает разность значений функции ошибки. Она возникает, когда в выборку добавляется один новый объект. Здесь мы демонстрируем поведение для двумерного пространства параметров. Рядом с точкой минимума θ^* среднее значение функции ошибки на $k + 1$ объектах $\mathcal{L}_{k+1}(\theta)$ стремится к тому же, но на k объектах $\mathcal{L}_k(\theta)$.

Выборка

$$\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}, \quad i = 1, \dots, m, \quad \mathbf{x} \in \mathcal{X}, \mathbf{y} \in \mathcal{Y}$$

Модель

Условное распределение $p(\mathbf{y}|\mathbf{x})$ аппроксимируется $f_{\boldsymbol{\theta}} : \mathcal{X} \rightarrow \mathcal{Y}$, $\boldsymbol{\theta} \in \mathbb{R}^P$.

Функция потерь

$$\mathcal{L}_m(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) \approx \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathbf{x}, \mathbf{y})} [\ell(f_{\boldsymbol{\theta}}(\mathbf{x}), \mathbf{y})]$$

Изменение значения при добавлении одного объекта

$$\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta}) = \frac{1}{k+1} (\ell(f_{\boldsymbol{\theta}}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \mathcal{L}_k(\boldsymbol{\theta}))$$

Предположение о точке минимума

Предположение 1

Пусть θ^* является точкой минимума обеих функций $\mathcal{L}_k(\theta)$ и $\mathcal{L}_{k+1}(\theta)$, то есть $\nabla \mathcal{L}_k(\theta^*) = \nabla \mathcal{L}_{k+1}(\theta^*) = 0$.

Аппроксимация второго порядка

$$\mathbf{H}^{(k)}(\theta) = \nabla_{\theta}^2 \mathcal{L}_k(\theta) = \frac{1}{k} \sum_{i=1}^k \nabla_{\theta}^2 \ell(f_{\theta}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\theta)$$
$$\mathcal{L}_k(\theta) \approx \mathcal{L}_k(\theta^*) + \frac{1}{2}(\theta - \theta^*)^{\top} \mathbf{H}^{(k)}(\theta^*)(\theta - \theta^*)$$

Абсолютное изменение функции потерь

$$|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)| \leq \frac{1}{k+1} \left| \ell(f_{\theta^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\theta^*}(\mathbf{x}_i), \mathbf{y}_i) \right| +$$
$$+ \frac{1}{k+1} \|\theta - \theta^*\|_2^2 \left\| \mathbf{H}_{k+1}(\theta^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\theta^*) \right\|_2$$

Декомпозиция Гессиана

$$\mathbf{H}_i(\boldsymbol{\theta}) = \underbrace{\nabla_{\boldsymbol{\theta}\mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\boldsymbol{\theta}\mathbf{z}_i^\top}}_{\text{G-term}} + \underbrace{\sum_{k=1}^K \frac{\partial \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial z_{ik}} \nabla_{\boldsymbol{\theta}}^2 z_{ik}}_{\text{H-term}}$$

Аппроксимация Гессиана

В задаче K -классовой классификации спектр Гессиана состоит из двух частей¹: “bulk” (большое количество около нуля) и “outliers” (ровно K ненулевых). Поэтому часто для изучения нормы Гессиана пренебрегают H -членом, то есть

$$\mathbf{H}_i(\boldsymbol{\theta}) \approx \nabla_{\boldsymbol{\theta}\mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\boldsymbol{\theta}\mathbf{z}_i^\top}.$$

¹Sagun, L. et al. (2017). Empirical analysis of the hessian of over-parametrized neural networks.

Papayan, V. (2018). The full spectrum of deepnet Hessians at scale: Dynamics with SGD training and sample size.

Ghorbani, B. et al. (2019). An Investigation into Neural Net Optimization via Hessian Eigenvalue Density.

Полносвязная нейронная сеть

Пусть $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{y} \in \mathbb{R}^K$. Рассмотрим L -слойную сеть для задачи классификации, то есть $f_{\theta}(\mathbf{x}) = \mathbf{z}$ и $\ell(\mathbf{z}, \mathbf{y}) = \text{CE}(\mathbf{p}, \mathbf{y}) = -\sum_{k=1}^K y_k \log p_k$:

$$\begin{aligned}\mathbf{z}^{(p)} &= \mathbf{W}^{(p)} \mathbf{x}^{(p)} + \mathbf{b}^{(p)}, \\ \mathbf{x}^{(p+1)} &= \sigma(\mathbf{z}^{(p)}),\end{aligned}$$

где $\text{softmax}(\mathbf{z}) = \mathbf{p}$, а $\sigma(\mathbf{x}) = [\mathbf{x} \geq 0]$ $\mathbf{x}$ есть функция активации ReLU.

Теорема 1 (об ограниченности нормы Гессiana)

Пусть задана L -слойная полносвязная нейронная сеть с функцией активацией ReLU и без параметров смещения, применяемая для решения задачи K -классовой классификации. Если выполнено следующее: $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$ и $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ для всех слоев $p = 1, \dots, L$ в сети и для всех объектов $i = 1, \dots, m$ в наборе данных, то для любого объекта $i = 1, \dots, m$ верно следующее неравенство:

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1}.$$

Лемма 1 (о пропорциональности нормы Гессiana)

Если каждый параметр модели ограничен константой $M > 0$, то есть $|w_{ij}^{(p)}| \leq M$ для всех $i, j = 1, \dots, h$ и для всех слоев $p = 1, \dots, L$, тогда в условиях Теоремы 1 верно следующее:

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq L\sqrt{2}M_{\mathbf{x}}^2(hM)^{2L} + \sqrt{2}\frac{(hM)^2((hM)^{2L} - 1)}{(hM)^2 - 1}.$$

Таким образом, верна следующая пропорция:

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \propto L(hM)^{2L}.$$

Лемма 2 (о сходимости абсолютной разности функции потерь)

Пусть точка θ выбрана так, что $\|\theta - \theta^*\|_2^2 \leq R^2$ для некоторого $R > 0$. Если существует неотрицательная константа M_ℓ , что $|\ell(f_{\theta^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_\ell$ для всех объектов $i = 1, \dots, m$ в наборе данных, то в условиях Теоремы 1 верно следующее:

$$|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)| \leq \frac{2}{k+1} \left(M_\ell + \left(L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1} \right) R^2 \right) \rightarrow 0 \text{ при } k \rightarrow \infty.$$

Таким образом, верна следующая пропорция:

$$|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)| \propto \frac{L(hM)^{2L}R^2}{k}.$$

- **Задача:** классификация изображений;
- **Выборка:** MNIST, CIFAR10;
- **Архитектура:** полносвязная L -слойная сеть со скрытым размером h на каждом слое и ReLU после каждого из них;
- **Варьирование архитектуры:** фиксируем число слоев L и варьируем размер скрытого слоя h ;
- **Постановка эксперимента:**
 1. Проводим $N = 10$ независимых обучений модели на полном наборе данных $\rightarrow$ получаем набор точек $\hat{\theta}_1, \dots, \hat{\theta}_N$;
 2. По мере обучения подсчитываем Ассигасу на отложенной выборке;
 3. Подсчитываем $\left| \mathcal{L}_{k+1}(\hat{\theta}_n) - \mathcal{L}_k(\hat{\theta}_n) \right|$ для всех $k = 1, \dots, m$ и $n = 1, \dots, N$;
 4. Повторяем 3 пункт $B = 100$ раз, используя разный порядок добавления, усредняем результаты;
 5. Усредняем результаты по $N = 10$ обучениям.

Сходимость поверхности в зависимости от размера выборки




Рис. 2: Зависимость абсолютного значения разности значений функции ошибки от доступного размера выборки. Графики, полученные на наборах данных MNIST и CIFAR10, демонстрируют сходимость поверхности функции потерь для различных наборов гиперпараметров модели.

Связь между качеством модели и сходимостью функции потерь




Рис. 3: Зависимость Ассурасу на отложенной выборке от значения абсолютной разности функции потерь на обучающей выборке. Полученные на наборах данных MNIST и CIFAR10 графики показывают, что чем меньше становится изменение поверхности функции потерь, тем выше качество модели.

1. Доказаны теоретические результаты о сходимости поверхности функции потерь в полносвязной нейронной сети при увеличении размера выборки;
2. Вычислительный эксперимент демонстрирует справедливость полученных результатов на практике;
3. В результате экспериментов также получено, что сходимость поверхности функции потерь связана с качеством модели на отложенной выборке;
4. Дальнейшее исследование лежит в направлении формулировки критерия достаточного размера выборки, используя сходимость функции ошибки.

1. **N. Kiselev**, A. Grabovoy (2025). Sample size determination: likelihood bootstrapping. Computational Mathematics and Mathematical Physics, 65(2), 416-423.
2. **N. Kiselev**, A. Grabovoy (2025). Sample size determination: posterior distributions proximity. Computational Management Science, 22(1), 1.
3. **N. Kiselev**, A. Grabovoy (2024). Unraveling the hessian: A key to smooth convergence in loss function landscapes. Doklady Mathematics, 110(1), 49–61.
4. V. Meshkov, **N. Kiselev**, A. Grabovoy (2024). ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks. In 2024 Ivannikov Ispras Open Conference (ISPRAS) (pp. 1-10). IEEE.